



Departamento de
Informática

Relatório Final

Leonor Rebola

Adriana Abreu

Faculdade de Engenharia
Departamento de Informática
Licenciatura em Inteligência Artificial e Ciência de Dados

Covilhã, Junho 2026



Departamento de
Informática

Relatório Final

Leonor Rebola

Nº Estudante 53663

Adriana Abreu

Nº Estudante 53672

Professor: Sebastião Pais
*Professor de Extração e Transformação de Dados,
Universidade da Beira Interior*

Faculdade de Engenharia
Departamento de Informática
Licenciatura em Inteligência Artificial e Ciência de Dados

Covilhã, Junho 2026

CONTEÚDO

Conteúdo	4
Lista de Figuras	5
1 Extração	6
2 Transformação	7
3 Carregamento	8
4 Visualização	9

LISTA DE FIGURAS

4.1	Top 10 géneros mais populares	9
4.2	Relação entre energia e dançabilidade	10
4.3	Quantidade de músicas explícitas no dataset	10
4.4	Artistas em destaque	11

EXTRAÇÃO

Para este trabalho escolhemos utilizar três fontes de dados com tema em músicas do spotify. A primeira foi uma pasta de jsons que foi retirada através de um site que contém arquivos de outros sites na internet, visto que os dados que queríamos utilizar já não existiam no site no presente. A segunda fonte foi retirada do kaggle onde continha dados diferentes como popularity e danceability. Por fim, retiramos dados de uma API do próprio Spotify, onde tivemos que criar uma aplicação e conseguir uma chave para termos acesso aos dados.

TRANSFORMAÇÃO

Nesta parte, começámos por transformar o ficheiro .json para .csv para trabalhar de melhor forma. Depois, unimos os ficheiros através da `track_id`, que foi extraída do campo `track_uri`. Esta chave permitiu fazer o join entre o dataset principal e os dados provenientes da Spotify API, resultando num único dataset com toda a informação consolidada.

Com a junção, fomos verificar os valores em falta, onde repáramos que as colunas `release_date` e `explicit` tinham diversos valores em falta, onde os mesmos foram preenchidos pela média por artista. Relativamente aos valores duplicados, removemos músicas que estavam repetidas dentro das playlists.

Também, transformámos a coluna `duration_ms` de segundos para segundos e a coluna `explicit` foi normalizada com os 0's (False) e 1's (True).

Por fim, criámos duas camadas de dados - **silver e gold** - em que a camada silver representa o dataset completo após limpeza e a camada gold representa o dataset com as colunas usadas para a análise.

CARREGAMENTO

No carregamento colocámos os dados que estavam nos nosso pcs para o SQL Management, para em seguida podermos utilizasr esta base de dados para a visualização. Conectámos o Visual Studio ao SQL apartir de código python e verificámos no final que os dados estavam todos corretos e nas colunas corretas.

VISUALIZAÇÃO

Para esta parte, decidimos responder às seguintes questões:

- Quais são os géneros mais populares?
- Existe relação entre energia e dançabilidade?
- Quantas músicas explícitas estão presentes?
- Quais são os artistas em destaque?

Os gráficos gerados foram os seguintes:




Figura 4.1: Top 10 géneros mais populares




Figura 4.2: Relação entre energia e dançabilidade




Figura 4.3: Quantidade de músicas explícitas no dataset




Figura 4.4: Artistas em destaque

Onde chegámos às seguintes conclusões:

- O género mais popular é Hip-Hop, seguido de Pop-Film e Latino.
- É possível verificar uma linearidade entre a energia e a dançabilidade de um género musical e, por esse motivo, podemos concluir que as duas variáveis correlacionam-se.
- A grande maioria das músicas não são explícitas, representando 98.27%.
- Os artistas predominantes nas playlists presentes no dataset são os Arctic Monkeys, com 30 músicas, seguidos dos BTS e dos Nirvana.

Relatório GitHub: <https://github.com/leonorrebola9/projetoetl>